

Contents

1	¿Qué es esto?	1
2	2. Random variable generation	2
2.1	Introduction	2
2.1.1	The inverse transformation	2
2.1.2	2.2: General transformation methods	6
2.1.3	2.2.1 A normal generator	7
2.1.4	2.2.2 Discrete distributions	9
3	Notación	11

Chapter 1

¿Qué es esto?

Los ejercicios, desarrollos de argumentos y códigos realizados por mí mientras estudio el libro *Introducing Monte Carlo Methods with R* de Christian P. Robert y George Casella.

Chapter 2

2. Random variable generation

2.1 Introduction


2.1.1 The inverse transformation

Teorema 2.1.1

(p.44) Sea X una variable aleatoria continua, con funciones de densidad f_X y F_X , respectivamente, con $F_X : \mathbb{R} \rightarrow (0, 1)$ invertible. La variable aleatoria

$$U = F_X \circ X$$

tiene distribución $\mathcal{U}(0, 1)$.



Demostración. En efecto, sea $u \in (0, 1)$. Puesto que por hipótesis F_X es invertible (o, equivalentemente, biyectiva), existe un único $x \in \mathbb{R}$ tal que $F_X(x) = u$. Se tiene entonces que

$$\begin{aligned} P(U \leq u) &= P(F_X(X) \leq F_X(x)) = P(F_X^{-1}(F_X(X)) \leq F_X^{-1}(F_X(x))) \\ &= P(X \leq x) = F_X(x) = u. \end{aligned}$$




Figure 2.1: a

□

El resultado dual se da a continuación.

Ejercicio 1

(2.1, p.44) Si X es una variable aleatoria con función de acumulación F_X , defina a la **inversa generalizada de F_X** como sigue:

$$\forall u \in (0, 1) : F_X^-(u) := \inf\{x : F_X(x) \geq u\}. \quad (2.1)$$

Demuestre que si U es una variable aleatoria con distribución $U(0, 1)$, entonces

$$F_X^- \circ U \sim X.$$



Demostración.

Sea $Y : \Omega \rightarrow \mathbb{R}$ la composición $F_X^- \circ U$. Debemos demostrar que

$$\forall z \in \mathbb{R} : P(Y \leq z) = P(X \leq z).$$

Sea pues $z \in \mathbb{R}$.

- a) Por ser F_X una función de acumulación, es una función creciente, luego, los eventos

$$(X \leq z) \text{ y } (F_X(X) \leq F_X(z))$$

son iguales; además, según el teorema 2.1.1, $F \circ X \sim U$; así,

$$P(X \leq z) = P(F_X(X) \leq F_X(z)) = P(U \leq F_X(z)). \quad (2.2)$$

- b) Por la definición de F^- en términos de un ínfimo, se sigue de inmediato que

$$\begin{aligned} P(Y \leq z) &= P(F_X^-(U) \leq z) = P(\{w \in \Omega : F_X^-(U(w)) \leq z\}) \\ &= P(\{w \in \Omega : U(w) \leq F_X(z)\}) = P(U \leq F_X(z)), \end{aligned}$$




Figure 2.2: Definición de F_X^- .

o sea, que

$$P(Y \leq z) = P(U \leq F_X(z)); \quad (2.3)$$

de (2.2) y (2.3) se sigue, como queríamos, que $P(X \leq z) = P(Y \leq z)$.

□

Ejercicio 2

(2.2, p. 45) Se dan algunas funciones de probabilidad. Calcule las correspondientes funciones de acumulación, y en base a estas y los resultados anteriores, simule via una transformación de variables aleatorias uniformes la distribución dada. Comparar el resultado obtenido con las gráficas hechas llamando a la distribución en R.

Solución

a) **Distribución logística:** la pdf es

$$f(x) = \frac{1}{\beta} \frac{e^{-(x-\mu)/\beta}}{(1 + e^{-(x-\mu)/\beta})^2} \quad (2.4)$$

(al parámetro μ se le llama **localización**, y al β **escala**). Integrando, calculamos que

$$\forall x \in \mathbb{R}: F(x) = \frac{1}{1 + e^{-(x-\mu)/\beta}};$$

la inversa de esta función es

$$F^{-1}(u) = \ln \left(\left(\frac{u}{1-u} \right)^\beta \right) + \mu,$$

luego, según el ejercicio 1, si $U \sim U(0, 1)$, la variable aleatoria

$$Y = \ln \left(\left(\frac{U}{1-U} \right)^\beta \right) + \mu$$

tiene a la función (2.4) como función de distribución.

Los valores de default de los parámetros de la distribución logística en **rstudio** son

$$\mu = 0, \quad \beta = 1;$$

a continuación comprobamos con un experimento numérico en **rstudio** que las variables aleatorias

$$X = \text{logistic}(\mu = 0, \beta = 1) \text{ y } Y = \ln \left(\frac{U}{1-U} \right) \quad (2.5)$$

parecen tener la misma distribución.




Figure 2.3: Histogramas de distribuciones logísticas (tamaño de muestra: 10^4) usando las variables aleatorias (2.5).

Código de R empleado para generar la imagen:

```
> Nsim=10^4
> U=runif(Nsim)
> X=rlogis(Nsim)
> Y=log(U/(1-U))
> par(mfrow=c(1,2))
> hist(X, freq=FALSE, main='Logist from R')
> hist(Y, freq=FALSE, main='Logist from uniform')
```

b) **Distribución de Cauchy:** la pdf es

$$f(x) = \frac{1}{\pi\sigma} \frac{1}{1 + \left(\frac{x-\mu}{\sigma}\right)^2}.$$

Después de integrar se llega a que

$$\forall x \in \mathbb{R} : F(x) = \frac{1}{2} \frac{1}{\pi} \arctan\left(\frac{x-\mu}{\sigma}\right).$$

La inversa de esta transformación es

$$F^{-1}(u) = \mu + \sigma \tan\left(\pi u - \frac{\pi}{2}\right), \quad 0 < u < 1,$$

luego, según el ejercicio 1, si $U \sim U(0, 1)$, la variable aleatoria

$$F^{-1}(U) = \mu + \sigma \tan\left(\pi U - \frac{\pi}{2}\right)$$

tiene distribución de Cauchy con parámetros μ y σ .

Haciendo $\mu = 0$ y $\sigma = 1$, podemos graficar los histogramas de 10^4 variables aleatorias

$$X \sim \text{Cauchy}(\mu, \text{sigma}), \text{ y } Z = \mu + \sigma \tan\left(\pi U - \frac{\pi}{2}\right) \quad (2.6)$$

y compararlos; como se ve en la figura, resultado de correr el código de más abajo, estos histogramas son casi idénticos.

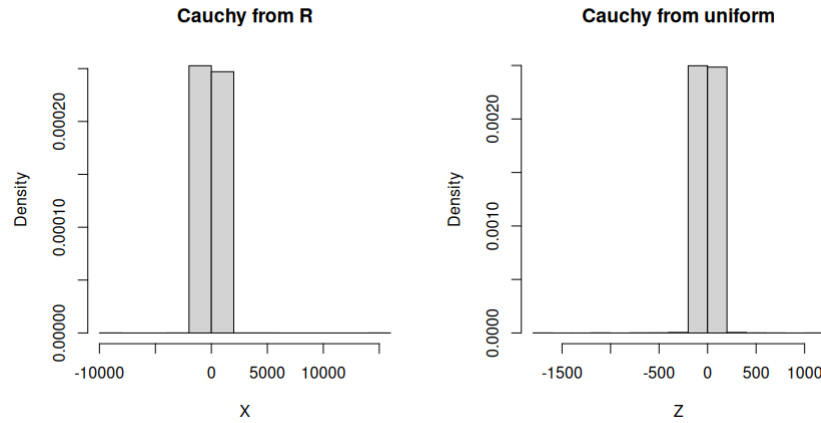


Figure 2.4: Histogramas de distribuciones Cauchy (tamaño de muestra: 10^4) usando las variables aleatorias (2.6).

Código de R empleado para generar la imagen:

```
> Nsim=10^4
> U=runif(Nsim)
> X=rcauchy(Nsim)
> Z=tan(3.1416*(U-0.5))
> par(mfrow=c(1,2))
> hist(X, freq=FALSE, main='Cauchy from R')
> hist(Z, freq=FALSE, main='Cauchy from uniform')
```

2.1.2 2.2: General transformation methods

Según un ejemplo del libro, si $U \sim U(0, 1)$, entonces $-\ln(U) \sim \text{Exp}(1)$. Se establecen además las siguientes relaciones:

Teorema 2.1.2

Sea $\{X_i\}_{i \in \mathbb{N}}$ iid $\text{Exp}(1)$ variables aleatorias. Para cualesquiera $a, b, v \in \mathbb{N}^*$,

$$Y = 2 \sum_{j=1}^v X_j \sim \chi_{2v}^2, \quad (2.7)$$

$$Y = \beta \sum_{j=1}^a X_j \sim \mathcal{G}(a, \beta), \quad (2.8)$$

$$Y = \frac{\sum_{j=1}^a X_j}{\sum_{j=1}^{a+b} X_j} \sim \text{Beta}(a, b). \quad (2.9)$$

Comprobemos las fórmulas (2.7), (2.8) y (2.9) con algunas simulaciones en R.

```
> U=runif(3*10^4)
> U=matrix(data=U, nrow=3)
```




Figure 2.5: Explicación gráfica del proceso de simulación.

```

> X=-log(U)
> Y=2*apply(X, 2, sum)
> Z=rchisq(10^4, df=6)
> par(mfrow=c(1,2))
> hist(Z, freq=FALSE, main='Chi df=6 from R')
> hist(Y, freq=FALSE, main='Chi df=6 from Exp')

```

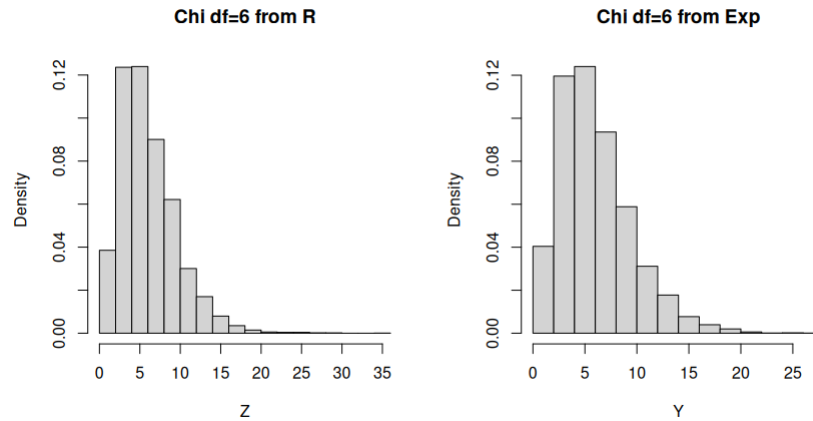


Figure 2.6: Histogramas de $Y = 2(X_1 + X_2 + X_3)$, con $X_i, 1 \leq i \leq 3$ iid $Exp(1)$ y de $Z \sim \chi_6^2$.

No pude simular correctamente las otras dos distribuciones!

2.1.3 2.2.1 A normal generator

Teorema 2.1.3

(**Box-Muller**) if U_1 and U_2 are iid uniforms in $]0, 1[$, then the variables

$$X_1 := \sqrt{-2\log(U_1)}\cos(2\pi U_2)$$

and

$$X_2 := \sqrt{-2\log(U_1)}\sin(2\pi U_2)$$

are iid $N(0,1)$.

```

> n = 10**4
> U1 = runif(n)
> U2 = runif(n)
> X1 = sqrt(-2*log(U1))*cos(2*pi*U2)
> X2 = sqrt(-2*log(U1))*sin(2*pi*U2)
> N = rnorm(n,0,1)
> par(mfrow=c(1,3))
> hist(X1, freq=FALSE, main='Primera normal de BM')
> hist(X2, freq=FALSE, main='Segunda normal de BM')
> hist(N, freq=FALSE, main='Normal de R')

```

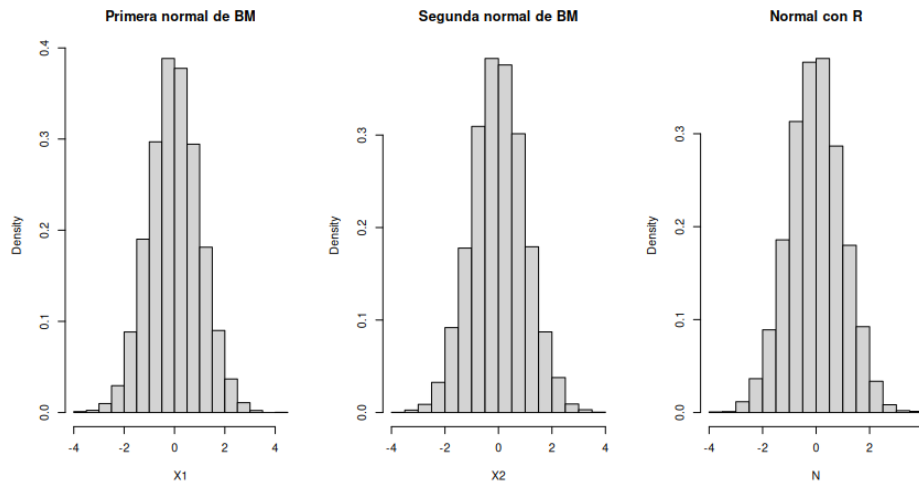




Figure 2.7: Usamos el algoritmo de Box-Muller para generar dos normales estandar. Comparamos sus histogramas con el de una normal generada por R.

Box-Muller

Figure 2.8



Ejercicio 3

(2.3) Podemos usar el **teorema del límite central** para generar una distribución normal a partir de variables aleatorias uniformes e independientes.

Sean $U_i \sim U[-1/2, 1/2]$, $0 \leq i \leq 12$. Se calcula que, para toda i , $E[U_i] = 0$ y

$Var[U_i] = 1/12$. Si $Z := \sum_{i=1}^{12} U_i$, entonces

$$E(Z) = \sum_{i=1}^{12} E(U_i) = 0$$

y

$$Var(Z) = \sum_{i=1}^{12} Var(U_i) = 1;$$

ahora bien, según el TLC, la variable aleatoria

$$\frac{Z - E(Z)}{\sqrt{Var(Z)}} = Z$$

tiende en probabilidad a $N(0,1)$

```
> n = 10**4
> Z1 = rnorm(n, 0, 1)
> U = runif(12*10**4)
> U = matrix(data = U, nrow=12)
> Z2 = apply(U, 2, sum)
> U1 = runif(n)
> U2 = runif(n)
> Z3 = sqrt(-2*log(U1))*cos(2*pi*U2)
> par(mfrow=c(1,3))
> hist(Z1, freq = FALSE, main = "Normal con R")
> hist(Z2, freq = FALSE, main = "Normal con TLC")
> hist(Z3, freq = FALSE, main = "Normal con BM")
```




Figure 2.9: Resultados de las simulaciones en R. Por lo general se prefiere usar BM a TLC, pues el primero da lugar a v.a. que en efecto tienen distribuciones $N(0,1)$, mientras que el segundo método siempre da aproximaciones.

2.1.4 2.2.2 Discrete distributions

A partir de una variable uniforme $U \sim U(0,1)$, también es posible generar distribuciones discretas. Sea P_θ una distribución cuyo soporte está contenido en \mathbb{Z} , y sea $X \sim P_\theta$.

Calcular a F_θ (la función de acumulación de la distribución) se reduce a calcular (y, en la práctica, guardar en la memoria) los siguientes números;

$$p_k := P(X \leq k) \quad (2.10)$$




Figure 2.10: Recuerde cómo se define la inversa generalizada de la función de acumulación F en (2.1).

La inversa generalizada F_θ^- de la función de acumulación dada es

$$\begin{aligned} F_\theta^- :]0, 1[&\longrightarrow \{p_k\}_{k \in \mathbb{Z}} \\ u &\longmapsto k \text{ si } p_{k-1} < u \leq p_k. \end{aligned}$$

Según el ejercicio 1, $X := F_\theta^- \circ U \sim P_\theta$.

Ejemplo 2.1.4

Este es el resultado de usar las ideas de esta sección para, a partir de números aleatorios de una distribución $U(0, 1)$, obtener una distribución binomial.




Figure 2.11: Figura generada usando el código de `generar_binomial.py`

Chapter 3

Notación

$$\mathbb{N}^* = \{1, 2, \dots\}$$